

Explorando o sentimento no Twitter sobre a implementação do ensino remoto no Brasil em face à COVID-19

Felipe Antonio Alves Leite¹

1

1. Introdução

O surgimento do novo Coronavírus mudou completamente a rotina das pessoas em função do seu alto nível de contágio e taxa de mortalidade não desprezível. Como forma de contornar problemas causados pelas restrições e medidas de distanciamento social estabelecidas para mitigar os crescentes índices de contágio, a tecnologia da informação, junto aos seus mecanismos de utilização remota, foi empregada para o estabelecimento de telemedicina, trabalho remoto e ensino a distância [Watson et al. 2020].

Em relação à educação, esforços de governos e instituições terciárias em todo o mundo foram empregados para utilizar tecnologias de informação e comunicação com o intuito de permitir a aprendizagem dos estudantes de forma não presencial durante a pandemia [Ali 2020]. No Brasil, muitas redes de ensino e instituições de ensino superior têm optado pela modalidade de ensino remoto [Arruda 2020]. O ensino remoto difere da abordagem de educação a distância (EAD), já que o primeiro diz respeito às atividades de ensino mediadas por tecnologias, mas orientadas pelos princípios da educação presencial [Arruda 2020]. Por sua vez, a EAD, ainda que tecnicamente e conceitualmente refira-se à mediação do ensino e da aprendizagem por meio de tecnologias, envolve planejamento anterior, considerações sobre o perfil de alunos e docentes e o desenvolvimento a médio e longo prazo de estratégias de ensino e aprendizagem que levem em consideração as dimensões síncronas e assíncronas [Moore et al. 2011, Arruda 2020].

Apesar de o ensino remoto ter permitido a retomada da aprendizagem de forma não-presencial, a realidade apresentada é bem diferente. Muitos alunos alegam dificuldade para acessar as aulas digitais ou afirmam que a experiência do ensino remoto está sendo ruim [Camacho et al. 2020]. Outro problema é a ineficácia das aulas a distância para quem não tem acesso à Internet [Camacho et al. 2020]. Ou seja, os impactos consistem tanto da dificuldade de adaptação à mudança do esquema escolar quanto da vulnerabilidade social enfrentada pelas pessoas neste período de pandemia [Camacho et al. 2020, Galletta et al. 2020].

Isso leva as pessoas a expressarem seus sentimentos nas redes sociais, como é o caso do Twitter, que recebe milhares de opiniões acerca do mais diversos assuntos todos os dias. Inclusive, temas como “EAD” e “ensino remoto” foram classificados como uns dos tópicos mais populares, com um alto volume de postagens em mídia social.

Com o objetivo de compreender o sentimento dos usuários brasileiros sobre os primeiros meses de introdução do ensino remoto no Brasil durante a pandemia de COVID-19 e também analisar fatores que podem ter contribuído para um determinado sentimento, este trabalho realizou um estudo de análise de sentimentos das mensagens da rede social Twitter. A Análise de Sentimentos (AS), também chamada de Mineração de Opinião, é a área de estudo que analisa os sentimentos e opiniões das pessoas acerca de entidades [Liu and Zhang 2012]. Estas entidades podem ser produtos, serviços, organizações,

indivíduos, problemas, eventos, tópicos e seus atributos; e as opiniões são expressas de forma não-estruturada, como em texto, por exemplo. Essa análise geralmente consiste em classificar uma opinião em um dentre três rótulos: *positiva*, *negativa* ou *neutra* [Liu and Zhang 2012, Yue et al. 2018, Alswaidan and Menai 2020].

Neste estudo, foram analisados fatores econômicos, sociais e geográficos a fim de compreender a visão dos alunos sobre a adoção do ensino remoto durante a pandemia de COVID-19. Desta forma, podemos identificar os problemas enfrentados pelos alunos e questionar se as técnicas adotadas estão sendo aplicadas corretamente neste período.

O restante deste trabalho está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados; a Seção 3 detalha a metodologia utilizada nesta pesquisa; enquanto que os resultados alcançados e suas discussões podem ser encontrados na Seção 5; e, por fim, a Seção 6 traz as considerações finais.

2. Trabalhos relacionados

A análise de sentimentos nas redes sociais tornou-se um grande tema de estudo [Yue et al. 2018, Alswaidan and Menai 2020]. Um número crescente de trabalhos tem apresentado novas técnicas de análise de sentimentos, além de estudos que analisam o sentimento das pessoas a respeito de temas específicos, a exemplo de educação e ensino [Yue et al. 2018, Alswaidan and Menai 2020]. Inclusive, o emprego da análise de sentimentos a respeito da educação durante período pandêmico já foi abordado também pela literatura, tais como os trabalhos de [AL-Rubaiee et al. 2016, Duong et al. 2020, Wang and Cruz 2020, Pastor 2020, Mostafa 2021].

Um destes trabalhos foi realizado por [AL-Rubaiee et al. 2016], os quais fizeram uso dos algoritmos *Support Vector Machine* (SVM) e *Naïve Bayes* (NB) para classificar a polaridade de *tweets* de estudantes da universidade King Abdulaziz, na Arábia Saudita. Os autores buscaram compreender a opinião dos universitários a respeito da EAD e consequentemente melhorar seus processos de ensino. Com os resultados, eles perceberam que o SVM alcançou uma maior precisão quando comparado ao NB. O trabalho em si apresentou uma técnica para classificar as opiniões, contudo não foram evidenciados os sentimentos que os estudantes possuíam a respeito da educação a distância.

No trabalho de [Duong et al. 2020], foram verificadas as implicações sociais que a pandemia de COVID-19 provocou em relação ao público em geral e aos estudantes do ensino superior nos EUA, a partir da extração de opiniões do Twitter. Os autores analisaram um período de dois meses, quando o distanciamento social em todo o país e o fechamento de escolas atraíram grandes preocupações. Utilizando técnicas de aprendizagem profunda e o modelo RoBERTa para classificar as opiniões, foi identificado que os estudantes publicaram mais *tweets* com teor negativo relacionados ao fechamento das escolas. Entretanto, a pesquisa, apesar de destacar a preocupação dos jovens e o sentimento de desaprovação em relação ao ensino remoto, não evidenciou os fatores que levaram os estudantes a terem esse posicionamento.

A fim de ter um entendimento mais completo em torno do cenário que a pandemia de COVID-19 ocasionou na educação dos EUA, [Wang and Cruz 2020] conduziram um estudo em larga escala sobre o assunto. Eles utilizaram um conjunto de dados georreferenciados do Twitter, abrangendo todo o país, durante partes da primavera, verão e outono

de 2020. No que diz respeito ao processo metodológico, foi utilizado o dicionário labMT para análise de sentimentos, o qual indicou uma predominância de sentimentos positivos. Contudo, os autores afirmam que esses resultados não são totalmente confiáveis, visto que a palavra “*positive*” (positivo), encontrada em muitos *tweets*, contribuiu bastante para classificação dos dados, embora o contexto da mensagem em alguns casos indicasse um sentimento contrário. Para a análise de conteúdo, os autores fizeram uso do LIWC, o qual mostrou os tópicos de maior preocupação entre os universitários, como financiamento e mensalidades. Porém, cabe ressaltar que a utilização de algoritmos mais robustos para classificação dos dados poderia ter dado uma maior confiança nos resultados obtidos.

Ainda, o trabalho de [Pastor 2020] teve como objetivo revelar o sentimento de estudantes da Universidade Estadual de Pangasinan, nas Filipinas, em relação à introdução do paradigma de ensino assíncrono em função da COVID-19. Diferentemente dos outros trabalhos apresentados nesta seção, a autora realizou a coleta de dados com base em um formulário contendo uma pergunta aberta, o qual foi enviado para os universitários via *messenger*. A pesquisa apontou alguns fatores que prejudicam a adoção do ensino remoto, como a conectividade à Internet, que, embora não seja tão rápida comparada a outros países, serve para lembrar a realidade vivenciada por vários estudantes durante este período de pandemia. Porém, vale ressaltar que o autor não especificou quais técnicas foram utilizadas para a análise de sentimentos.

Em seu trabalho, [Mostafa 2021] realizou análise de sentimentos em meio à pandemia de COVID-19, visando entender o sentimento dos alunos egípcios em relação ao processo de aprendizagem durante este período. Para o trabalho, os dados foram coletados através de um questionário realizado por meio de planilhas eletrônicas. No que diz respeito ao processo metodológico para classificação dos sentimentos, foi utilizado o algoritmo Word2vec combinado com os classificadores *Naïve Bayes*, SVM e Árvore de Decisão. Dessa forma, o autor pôde comparar o desempenho dos algoritmos, chegando à conclusão de que o *Naïve Bayes* foi superior no cenário avaliado. Contudo, ela reconhece que o tamanho da amostra utilizada foi relativamente pequeno.

Convém destacar que não foram encontrados trabalhos de pesquisa que abordassem o tema no contexto brasileiro. O presente trabalho busca, assim, contribuir com o estado da arte ao apresentar uma análise de sentimentos sob a perspectiva de estudantes brasileiros por meio da análise de *tweets* em português. Outra contribuição foi a construção de um conjunto de dados anotados sobre sentimentos e emoções relacionadas ao ensino remoto e à COVID-19.

3. Metodologia

Este trabalho, em sua perspectiva objetiva, é exploratório na medida em que busca proporcionar maior entendimento sobre um problema e também permitir a construção de hipóteses [Yin 2013]. Quanto a seu paradigma de pesquisa, ele pode ser definido como pragmático que visa, ao invés de encontrar a verdade ou a realidade, facilitar a resolução de problemas humanos, ao buscar a aplicação de “tudo que funciona” para resolver o problema e inclui uma combinação de diferentes estratégias de pesquisa [Creswell 2010]. Consequentemente, o pragmatismo tem uma forte base filosófica nos métodos mistos ou campos de pluralismo metodológico.

Com base em nossos objetivos e no paradigma pragmático, a metodologia utili-

zada consistiu em 3 etapas de desenvolvimento: 1) coleta de dados e anotação do corpus; 2) construção do modelo e classificação; 3) análise dos dados.

3.1. Coleta de dados e Anotação do corpus

Os *tweets*, isto é, os dados do Twitter, foram extraídos durante os períodos de 28/04/2020 a 02/06/2020 e 22/06/2020 a 31/07/2020 por meio de um software extrator construído através da biblioteca Python Tweepy. Para extrair *tweets* relacionados, palavras-chave e *hashtags* como “coronavirus”, “COVID”, “COVID-19”, “COVID19”, “ensino remoto” e “EAD” foram usadas. Ao todo, foram coletados 162.921 *tweets* escritos em Português.

Após a extração, 2.100 *tweets* foram rotulados manualmente pelos autores deste trabalho classificando a polaridade da opinião contida no *tweet* acerca do ensino remoto, ou seja, classificando-os em três classes: *positiva*, *negativa* e *neutra*. Optou-se por uma anotação balanceada, garantindo que a base dos dados rotulados contivesse 700 *tweets* para cada uma das três classes. A anotação balanceada foi escolhida como forma de não enviesar a classificação. Além disso, cada documento foi classificado por dois anotadores, tendo as divergências sido resolvidas, quando ocorreram, como forma de mitigar possíveis vieses também na anotação.

3.2. Pré-processamento dos dados

Para a posterior utilização dos dados coletados, foram necessárias técnicas de pré-processamento. Tendo as bibliotecas NLTK e *scikit-learn* sido utilizadas para esse fim.

Primeiramente, todos os *tweets* foram colocados em minúsculo e realizou-se a tokenização, isto é, a divisão dos textos em *tokens*, com o auxílio do *TweetTokenizer* da biblioteca NLTK. Então os *tokens* passaram por um processo de filtragem, na qual as URLs e os identificadores de usuários foram removidos. Optou-se por manter as *hashtags*, pois considerou-se que elas poderiam conter informações importantes para a classificação de opinião. Por fim, utilizou-se a técnica TF-IDF para transformar os documentos em vetores de características, etapa necessária para a utilização dos classificadores.

3.3. Construção do Modelo e Classificação

Para a realização da análise de sentimentos, foi desenvolvido um modelo para classificação de sentenças de texto em 3 classes de sentimentos (negativo, neutro e positivo). Para tanto, foi construída uma aplicação de em Python, com o auxílio da biblioteca *scikit-learn*. Cinco classificadores de Aprendizado de Máquina foram utilizados: *Multinomial Naïve Bayes*, SVM, *Random Forest*, uma rede neural MLP e o classificador de Regressão Logística. A escolha dos classificadores se deu pelo fato de os quatro primeiros serem os mais utilizados para mineração de texto com a Língua Portuguesa [Souza et al. 2018], ao passo que o de Regressão Logística também é considerado bastante útil para classificação de texto [Yu et al. 2011].

Os cinco classificadores foram combinados utilizando um Sistema de Múltiplos Classificadores, também conhecido como *ensemble*, o qual combina classificadores diferentes visando melhorar o desempenho da classificação [Woźniak et al. 2014]. Geralmente, essa combinação alcança resultados melhores que classificadores individuais [Vitório et al. 2019b], então optou-se por utilizá-la como forma de prover uma precisão maior na classificação dos *tweets*.

Com o mesmo objetivo apontado acima, também foi utilizada a técnica de *Active Learning* (AL). Esta é uma técnica de Aprendizado de Máquina semi-supervisionado que consiste na anotação de dados no decorrer da classificação, os quais são utilizados para retreinar o classificador. O método AL usa um conjunto inicial de dados rotulados para o primeiro treinamento do modelo. Então, uma estratégia de seleção é utilizada para solicitar o rótulo de novos dados a fim de atualizar o modelo de aprendizagem. Estes novos dados são aqueles considerados pela estratégia de seleção mais adequadas para o problema [Zimmermann et al. 2015].

Sendo assim, o *ensemble* de classificadores, tendo sido treinado com os 2.100 *tweets* anotados manualmente, foi utilizado para classificar os *tweets* restantes. O algoritmo, então, solicitava ao usuário o rótulo daqueles *tweets* para os quais os classificadores tiveram menos certeza da sua classe. Esta estratégia de seleção, que leva em conta a incerteza do classificador, é denominada *Uncertainty* [Vitório et al. 2019a]. E os *tweets* cujo rótulo foi fornecido eram adicionados ao modelo, melhorando-o. Neste trabalho, a biblioteca modAL [Danka and Horvath 2018] foi utilizada para implementação da técnica de AL.

Como, nesta pesquisa, lidou-se com um conjunto grande de dados distribuídos temporalmente, os quais são conhecidos como “fluxos contínuos de dados”, optou-se pela utilização das duas técnicas supracitadas (i.e., *Active Learning* e *ensembles*). Ao se trabalhar com fluxos de dados contendo opiniões, é possível se deparar com os chamados *opinion drifts*: mudanças que podem ocorrer nas opiniões das pessoas acerca de alguma entidade com o passar do tempo [Wang et al. 2013]. E ambas as técnicas utilizadas auxiliam no trato desse problema, melhorando a classificação.

Além disso, como forma de garantir um maior grau de confiança na classificação, foram selecionados apenas os *tweets* para os quais o *ensemble* teve uma certeza de pelo menos 60% para sua classe, além daqueles selecionados pela estratégia de AL. Dessa forma, 66.890 *tweets* foram considerados nesta pesquisa. Após a anotação automática de todos os *tweets*, 200 deles foram escolhidos aleatoriamente e anotados manualmente por um dos autores. Com essa anotação, pôde-se estimar a acurácia do classificador: 87%.

Por fim, foi realizada a identificação dos estados brasileiros aos quais pertenciam os autores dos *tweets* classificados. Sabe-se que grande parte dos usuários do Twitter não fornece uma localização válida em seu perfil. Sendo assim, montou-se uma aplicação Python com a ajuda da biblioteca pyUFbr, a qual contém a lista de municípios brasileiros por estado, para identificar automaticamente as localidades.

3.4. Análise dos Dados

O objetivo deste estudo é fornecer um entendimento sobre os sentimentos dos brasileiros em relação aos primeiros meses de introdução do ensino remoto emergencial durante a pandemia, bem como quais fatores contribuíram para este sentimento. Para isso, foi definida a seguinte questão geral de pesquisa: *Qual a visão que a maioria dos alunos possuem em relação aos primeiros meses de implantação do ensino remoto emergencial?*

Também definimos outras questões de pesquisa específicas para orientar e estruturar a análise e síntese de dados e evidências, a exemplo de:

- O estado e a cidade em que a pessoa está situada pode ser um fator que influencia o seu sentimento?

- Habitar em cidades que possuem maior ou menor riqueza fazem as pessoas apresentarem uma opinião positiva ou negativa acerca do ensino remoto?
- De maneira geral, quais são os fatores associados ao sentimento dos alunos em relação ao ensino remoto?

[Piteira] [Vilarinho and Leite 2015] [GIRARDI et al. 2009] [Haviaras et al. 2019]
[Dizeró et al. 1998] [?] [Mattos 2001] [Petri et al. 2019] [Reitz 2009]

Referências

- AL-Rubaiee, H. S., Qiu, R., Alomar, K., and Li, D. (2016). Sentiment analysis of arabic tweets in e-learning. *Journal of Computer Science*.
- Ali, W. (2020). Online and remote learning in higher education institutes: A necessity in light of covid-19 pandemic. *Higher Education Studies*, 10(3):16–25.
- Alswaidan, N. and Menai, M. E. B. (2020). A survey of state-of-the-art approaches for emotion recognition in text. *Knowledge and Information Systems*, 62(8):2937–2987.
- Arruda, E. P. (2020). Educação remota emergencial: elementos para políticas públicas na educação brasileira em tempos de covid-19. *EmRede-Revista de Educação a Distância*, 7(1):257–275.
- Camacho, A. C. L. F., Fuly, P., Santos, M., and Menezes, H. (2020). Alunos em vulnerabilidade social em disciplinas de educação à distância em tempos de covid-19. *Research, Society and Development*, 9:275973979.
- Creswell, J. W. (2010). Projeto de pesquisa métodos qualitativo, quantitativo e misto. In *Projeto de pesquisa métodos qualitativo, quantitativo e misto*. Artmed.
- Danka, T. and Horvath, P. (2018). modAL: A modular active learning framework for Python. available on arXiv at <https://arxiv.org/abs/1805.00979>.
- Dizeró, W. J., Vicentin, V. J., and Kirner, C. (1998). Estudo de interação para um sistema de ensino a distância baseado em interfaces de realidade virtual. In *Atas I Workshop sobre Fatores Humanos em Sistemas Computacionais (IHC 98)*, Campinas, SP, pages 1–8.
- Duong, V., Pham, P., Yang, T., Wang, Y., and Luo, J. (2020). The ivory tower lost: How college students respond differently than the general public to the covid-19 pandemic. *arXiv preprint arXiv:2004.09968*.
- Galletta, D. F., Gaskin, J. E., Koch, H., Anderson, G., Jessup, L., King, J. L., Lowry, P. B., and Wetherbe, J. (2020). Educational disruption & rising faculty expectations. In *Proceedings of AMCIS 2020*.
- GIRARDI, L. H., CARGNELUTTI FILHO, A., and STORCK, L. (2009). Erro tipo ie poder de cinco testes de comparação múltipla de médias. *Rev. Bras. Biom*, 27(1):23–36.
- Haviaras, M. et al. (2019). A formação inicial de futuros pedagogos em instituições de ensino superior privadas do município de curitiba para a utilização de tecnologias educacionais.
- Liu, B. and Zhang, L. (2012). *A Survey of Opinion Mining and Sentiment Analysis*, pages 415–463. Springer US, Boston, MA, EUA.

- Mattos, M. M. (2001). Construção de abstrações em lógica de programação. In *Anais do XXI Congresso da Sociedade Brasileira de Computação, Fortaleza*.
- Moore, J. L., Dickson-Deane, C., and Galyen, K. (2011). e-learning, online learning, and distance learning environments: Are they the same? *The Internet and Higher Education*, 14(2):129–135.
- Mostafa, L. (2021). Egyptian student sentiment analysis using word2vec during the coronavirus (covid-19) pandemic. In Hassanien, A. E., Slowik, A., Snášel, V., El-Deeb, H., and Tolba, F. M., editors, *Proceedings of the International Conference on Advanced Intelligent Systems and Informatics 2020*, pages 195–203, Cham. Springer International Publishing.
- Pastor, C. K. L. (2020). Sentiment analysis on synchronous online delivery of instruction due to extreme community quarantine in the philippines caused by covid-19 pandemic. *Asian Journal of Multidisciplinary Studies*, 3(1):1–6.
- Petri, G., von Wangenheim, C. G., and Borgatto, A. F. (2019). Meega+: Um modelo para a avaliação de jogos educacionais para o ensino de computação. *Revista Brasileira de Informática na Educação*, 27(03):52–81.
- Piteira, M. F. Contribuição para avaliação da usabilidade.
- Reitz, D. S. (2009). Avaliação do impacto da usabilidade técnica e pedagógica no desempenho de aprendizes em e-learning.
- Souza, E., Costa, D., Castro, D. W., Vitorio, D., Teles, I., Almeida, R., Alves, T., Oliveira, A. L. I., and Gusmão, C. (2018). Characterising text mining: a systematic mapping review of the portuguese language. *IET Software*, 12(2):49–75.
- Vilarinho, L. R. G. and Leite, M. P. (2015). Avaliação de jogos eletrônicos para uso na prática pedagógica: ultrapassando a escolha baseada no bom senso. *RENOTE*, 13(1).
- Vitório, D., Souza, E., and Oliveira, A. L. I. (2019a). Evaluating active learning sampling strategies for opinion mining in brazilian politics corpora. In *19th EPIA Conference on Artificial Intelligence*, pages 695–707, Cham. Springer.
- Vitório, D., Souza, E., and Oliveira, A. L. I. (2019b). Using active learning sampling strategies for ensemble generation on opinion mining. In *8th Brazilian Conference on Intelligent Systems (BRACIS)*, pages 114–119. IEEE.
- Wang, D., Feng, S., Wang, D., and Yu, G. (2013). Detecting opinion drift from chinese web comments based on sentiment distribution computing. In *Web Information Systems Engineering – WISE 2013*, pages 72–81.
- Wang, Z. and Cruz, I. F. (2020). Analysis of the impact of covid-19 on education based on geotagged twitter. *COVID-19*, page 15–23, New York, NY, USA. Association for Computing Machinery.
- Watson, R., Corbett, J., Galletta, D. F., Ives, B., Mandviwalla, M., and Tremblay, M. (2020). Covid-19 and is: Challenges and opportunities for people, careers, and institutions. In *Proceedings of AMCIS 2020*.
- Woźniak, M., Graña, M., and Corchado, E. (2014). A survey of multiple classifier systems as hybrid systems. *Information Fusion*, 16:3 – 17.

- Yin, R. K. (2013). *Case study research: Design and methods*. Sage publications.
- Yu, H.-F., Huang, F.-L., and Lin, C.-J. (2011). Dual coordinate descent methods for logistic regression and maximum entropy models. *Machine Learning*, 85(1-2):41–75.
- Yue, L., Chen, W., Li, X., Zuo, W., and Yin, M. (2018). A survey of sentiment analysis in social media. *Knowledge and Information Systems*, 60(2):617–663.
- Zimmermann, M., Ntoutsi, E., and Spiliopoulou, M. (2015). Incremental active opinion learning over a stream of opinionated documents. *arXiv preprint arXiv:1509.01288*.